

# Implementação de um sistema BCI-SSVEP

Leonardo C. S. Marotta <sup>1</sup>, *RafaelFernandesAlmeida*<sup>2</sup>, *RamonFernandesViana*<sup>3</sup>

2021.08.28, V-2.0

## Resumo

Este artigo contempla os conhecimentos adquiridos e testados pela disciplina CEA743 — Tópicos Especiais em Telecomunicações III onde foram submetidos um conjunto de dados de potencial evocado de estado estável(SSVEP) como referência adquirida com uma interface cérebro-computador (BCI) ortográfica de 40 alvos. Este conjunto de dados consiste em amostragens de eletroencefalograma(EEG) de 64 canais de 35 indivíduos saudáveis(8 experientes e 27 ingênuos) enquanto realizavam uma tarefa de seleção de alvo guiada por sugestão sendo o procedimento de modulação de frequência e fase(JFPM). Os estímulos foram através de variações nas frequências entre 8 Hz a 15,8 Hz com intervalo de 0,2 Hz, também aplicado uma diferença de fase entre duas frequências adjacentes de 0,5. A mostragem de cada individuo contém os dados de seis blocos de 40 tentativas correspondentes as todas as 40 oscilações indicadas por uma pista visual ordenada aleatoriamente, sendo os estímulos em cada tentativa com uma duração de cinco segundos. O conjunto de dados será submetido a técnicas de pré-processamento(CCA e CAR), extração de características(FFT e Welch), seleção de características utilizando o coeficiente de Pearson e os métodos de Classificação SVM e MLP com intuito de relacionar a eficiência e viabilidade dos algoritmos.

**Palavras-chave:** Interface cérebro-computador (BCI), Eletroencefalograma (EEG), Frequência articular e Modulação de fase (JFPM), Pré-processamento CCA, Pré-Processamento CAR, Extração de características FFT, Extração de características Welch, Seleção de Características, Classificação SVM, Classificação MLP.

## Abstract

This article contemplates the knowledge acquired and tested by the discipline CEA743 — Special Topics in Telecommunications III, where a steady state evoked potential dataset (SSVEP) was submitted as a reference acquired with a 40-target orthographic brain-computer interface (BCI). This dataset consists of 64-channel electroencephalogram (EEG) samples of 35 healthy subjects (8 experienced and 27 naive) while performing a suggestion-guided target selection task being the frequency and phase modulation procedure (JFPM). The stimuli were through variations in frequencies between 8 Hz to 15.8 Hz with an interval of 0.2 Hz, also applying a phase difference between two adjacent frequencies of 0.5. Each individual's display contains data from six blocks of 40 trials corresponding to all 40 oscillations indicated by a randomly ordered visual cue, with the stimuli in each trial lasting five seconds. The dataset will be submitted to pre-processing techniques (CCA and CAR), feature extraction (FFT and Welch), feature selection using the Pearson coefficient and the SVM and MLP Classification methods in order to relate the efficiency and viability of the algorithms.

**Keywords:** Brain-Computer Interface (BCI), Electroencephalogram (EEG), Joint Frequency and Phase Modulation (JFPM), CCA Pre-Processing, CAR Pre-Processing, FFT Feature Extraction, Welch Feature Extraction, Feature Selection, SVM Classification, MLP Classification.

## 1 Introdução

As interfaces BRAIN-computer (BCIs) fornecem aos humanos um novo canal de comunicação baseado na codificação e decodificação de informações com atividades cerebrais, através de dois possíveis procedimentos: Invasivo e não invasivo. Nos últimos anos, os BCIs baseados em eletroencefalograma (EEG) alcançaram um rápido progresso no desempenho, funcionalidade e praticidade. Especialmente, o desempenho do BCI foi substancialmente melhorado pelos aplicativos de processamento de sinal avançado e aprendizado de máquina.




Figura 1 – Eletrocorticograma (ECoG)

Fonte: Material Teórico disponibilizado (2021)



Figura 2 – Eletroencefalografia (EEG).

Fonte: Telepathy - An Introduction to Brain-Computer Interfaces

De maneira geral, os sistemas BCI não invasivos buscam reconhecer padrões específicos na eletroencefalografia de superfície com o intuito de associá-los com sinais de controle (diferentes classes). Tais padrões bioelétricos distinguíveis são induzidos por meio de diferentes estratégias que fundamentam os chamados paradigmas, dentre os quais se destacam a imagética de tarefas, os potenciais evocados - tais como os observados mediante tarefas de tomada de decisão (P300) - e os potenciais visuais evocados em regime permanente (SSVEP - *Steady-State Visually Evoked*

*Potentials*)[1]. Neste último caso, solicita-se ao usuário que se concentre em um dos diferentes estímulos visuais, i.e. fontes luminosas oscilando em diferentes frequências. O foco de atenção em uma fonte específica induz sincronismo da atividade elétrica do córtex visual com a frequência estimuladora visual, o que pode ser inferido a partir de técnicas adequadas de processamento de sinais (e.g. estimação de espectro).

No presente trabalho, quatro diferentes cenários envolvendo diferentes técnicas de pré-processamento e extração de características tiveram seus desempenhos avaliados. Tais cenários tiveram por objetivo central estabelecer um comparativo em relação à utilização da análise de correlação canônica (CCA - *canonical correlation analysis*) e o filtro CAR nas etapas de pré-processamento e depois, utilizando as técnicas baseadas na frequência, observar o desempenho na extração de características.

Tais comparativos motivaram discussões interessantes em relação a possíveis alternativas de processamento de sinais para sistemas BCI-SSVEP operando em tempo de execução e servirão de base para a próxima etapa da BCI de seleção das características.

Na etapa de seleção das características foi aplicada a seleção utilizando o coeficiente de correlação de Pearson. A seleção foi feita para os estímulos de 10Hz, 12hz e 15Hz e foram identificados os melhores eletrodos.

Na etapa de Classificação foram implementados as técnicas de classificação SVM e MLP e com essa etapa, analisado o desempenho da BCI aplicada.

## 2 Revisão de literatura

Em BCIs baseadas em SSVEP, estímulos visuais modulados em diferentes frequências são simultaneamente colocadas à frente do usuário. Os estímulos utilizados em artigos analisados foram apresentados em frequências de 6Hz, 7.5Hz, 10Hz, 12Hz e 15hz. Cada frequência é associada a um dispositivo de saída com um comando associado. Quando o usuário foca sua atenção em um estímulo específico, a correspondente frequência deste estímulo, ou sua harmônica, aparece dominantemente no espectro de frequência do sinal de EEG medido daquele usuário.




Figura 3 – Média de amplitude em função dos estímulos frequenciais

As aquisições dos estímulos (*trials*) são definidas anteriormente e tem uma duração de 12s aproximadamente. Tais gravações são repetidas várias vezes para um mesmo indivíduo e o EEG de superfície foi gravado e armazenado. Tais *trials* devem ser segmentados em janelas menores visando o aumento do número de observações e criando intervalos de tempo compatíveis com os de sistemas BCI operando em tempo de execução.

Diferentes tamanhos de janelas foram considerados para a análise comparativa durante o pré-processamento comparando as técnicas CCA e CAR. Na extração de características, foram comparadas técnicas entre o método de Welch, baseado na frequência, e o método CCA, baseado no tempo.

Foram considerados cinco diferentes cenários de processamento: (1)– extração de atributos utilizando a CCA e sem seleção de características; (2)– extração de atributos utilizando método de Welch com pré-processamento CAR e seleção de atributos utilizando DBI e wrappers; (3)– extração de atributos utilizando método de Welch com pré-processamento CCA e seleção de atributos utilizando DBI e wrappers; (4)–extração de atributos utilizando método de Welch com pré-processamento CAR e seleção de atributos utilizando DBI e número fixo de atributos; (5)– extração de atributos utilizando método de Welch com pré-processamento CCA e seleção de atributos utilizando DBI e número fixo de atributos (seis). [1]

Todos os métodos utilizaram um classificador linear baseado em mínimos quadrados, tendo por critério de decisão a classe mais frequente entre todas as comparações par a par. Os dados foram particionados por meio da estratégia de validação *leave M out*, com 70% dos trials para treinamento

e 30% para teste em 100 repetições, com escolha aleatória entre os trials de treinamento e teste[2].

## 3 Metodologia

### 3.1 Banco de Dados

Os sinais expostos aos procedimentos de pré-processamento e extração de característica presentes neste artigo podem ser classificados como conjunto de dados de potencial evocado de estado estável (SSVEP) como referência adquirida com uma interface cérebro-computador (BCI) ortográfica de 40 alvos. Estas amostragens selecionadas são provenientes de eletroencefalogramas (EEG) de 64 canais diferentes de indivíduos saudáveis, onde foram coletados 17 indivíduos femininos e 18 masculinos com divergência de idade entre 17 e 34 anos, sendo 8 experientes e 27 ingênuos nesta aplicação procedimental que era proposto a realização de uma seleção de alvo guiada por sugestão sendo o procedimento de modulação de frequência e fase (JFPM).

Os estímulos foram através de variações nas frequências entre 8 Hz a 15,8 Hz com intervalo de 0,2 Hz, em conjunto com a aplicação de uma diferença de fase entre duas frequências adjacentes de 0,5. Amostragem de cada indivíduo contém os dados de seis blocos de 40 tentativas correspondentes as todas as 40 oscilações, realocadas cronologicamente com a sequência de ensaios. O grupo foi exposto a uma pista visual ordenada aleatoriamente, fazendo com que cada sequência de imagens utilizadas fossem únicas e os estímulos para cada tentativa teve uma duração de apenas cinco segundos.

### 3.2 Pré-Processamento

A duração dos testes apesar de serem fixadas em 5 segundos, a aquisição final dos dados obteve uma temporização de 6 segundos devido a inicialização precoce para captar totalmente o sinal e a finalização tardia do mesmo. Foi necessário a alteração dos trials de 6 segundos para um segmento janelado menores, visando a remoção de 0.5 segundos iniciais e finais, com finalidade de remover os ruídos externos fora da faixa temporal do experimento. Foram considerados para a análise comparativa dos cenários de processamento, os quais envolveram variantes em termos

de técnicas de pré-processamento (CAR – *Common Average Reference* vs. CCA – *Análise de Correlação Canônica*).

### 3.2.1 Referência de Média Comum (CAR)

A técnica Referência de Média Comum, popularmente conhecida como CAR é uma ferramenta que considera cada um dos pontos medidos pelos eletrodos e realiza a média aritmética dos mesmos. Calculada a média, o valor resultante é subtraído de cada um dos eletrodos originando um valor de tensão que não contém valores dos ruídos que estavam presente simultaneamente em todos os eletrodos (FRIMAN; VOLOSYAK; GRÄSER, 2007). A expressão que sintetiza a CAR é:

$$Y_i^{CAR} = Y_i^{ER} - \frac{1}{n} \sum Y_j^{ER} \quad (1)$$

em que:

$$Y_i^{ER} \quad (2)$$

é o sinal coletado no  $i$ -ésimo eletrodo e  $n$  é o número total de eletrodos. Visando assim retirar os ruídos coincidentes que aparecem em todos os eletrodos.

### 3.2.2 Análise de Correlação Canônica (CCA)

O método de Análise de Correlação Canônica, popularmente conhecida como CCA é uma ferramenta estatística empregada quando dois grupos distintos de variáveis podem ter informações correlacionadas de forma implícita. A ideia por trás deste método está em encontrar uma combinação linear entre as variáveis que compõem o primeiro grupo, e depois fazer o mesmo para as variáveis do segundo grupo. A correlação entre as duas combinações lineares é definida. Em seguida, uma nova combinação linear é testada em ambos os grupos e mais uma vez se determina a correlação entre eles. Esse processo tem continuidade até que se esgote o tamanho do menor grupo ou de ambos. O foco principal é encontrar a combinação linear que resulta na maior correlação entre os dois grupos (ABU-ALQUMSAN; PEER, 2016).

Considerando duas variáveis aleatórias representadas pelas matrizes  $X$  e  $Y$  deve-se encontrar as matrizes de coeficientes canônicos  $Wx$  e  $Wy$  de modo que:

$$x = Wx^t X \quad (3)$$

$$y = Wy^t Y \quad (4)$$

O coeficiente de correlação entre as variáveis canônicas  $x$  e  $y$  denominado  $(x, y)$  deve ser então maximizado. Pela definição de correlação é possível descrever:

$$p(x, y) = \frac{E[xy]}{\sqrt{E[x^2]E[y^2]}} \quad (5)$$

$$p(x, y) = \frac{E[Wx^t xy Wy^t]}{\sqrt{E[Wx^t xx Wx^t]E[Wy^t yy Wy^t]}} \quad (6)$$

$$p(x, y) = \frac{[Wx^t Cxy Wy]}{\sqrt{[Wx^t Cxx Wx][Wy^t Cyy Wy]}} \quad (7)$$

Deste modo podemos concluir que as variâncias das variáveis  $x$  e  $y$  sejam 1. O problema da maximização se torna:

$$Wx, Wy = MAX; Wx^t Cxy Wy \quad (8)$$

Após empregado os multiplicadores de Lagrange para a solução deste problema de otimização é possível encontrar os seguintes resolução:

$$p(x, y) = \sqrt{\lambda_{max}(TT^T)} \quad (9)$$

Sendo o máximo autovalor representado por:

$$\lambda_{max} \quad (10)$$

O sinal a ser utilizado nos próximos estágios da BCI é então mapeado através:

$$x = Wx^t X \quad (11)$$

## 3.3 Extração de Características

Os sinais SSVEP são classificados por meio de métodos baseados na análise da densidade espectral (PSD) ou da análise da correlação canônica. São empregados algoritmos para que a máquina passe pelo processo de aprendizagem para a classificação dos estímulos. No presente trabalho será analisado o método de estimativa da PSD que é realizado por meio da FFT após o processo de janelamento.

### 3.3.1 Transformada Rápida de Foutier (FFT)

A aplicação da Transformada Rápida de Foutier(FFT) permite fazer uma extração simples e rápida de características nos sinais coletados do EEG nos corretos eletrodos. Para o trabalho,

foram avaliados os espectros de sinais cerebrais registrados no canal Oz e filtrados pelas técnicas de CAR e CCA na etapa de pré-processamento.

Após a aplicação da FFT, pode ser observado por meio dos espectros registrados, que as características podem ser extraídas por meio da magnitude da FFT aplicada. A magnitude da FFT terá um valor bem definido na frequência em que ocorre o estímulo e sempre maior que as demais frequências.

Esta é uma técnica simples da extração de características para sistemas BCI-SSVEP mas que requer um sinal cerebral bem pré-processado e devem ser evitados frequências que são harmônicas para que a taxa de erro da BCI seja baixa.

### 3.4 Seleção de Características

Quando tratamos uma base de dados relacionada a BCI é importante levar em consideração que as técnicas aplicadas com eficiência não necessariamente podem ser utilizadas como padrão para outras bases de dados a serem analisadas posteriormente. A etapa de seleção de características é uma ferramenta importante neste processo, sendo utilizada para determinar as características mais relevantes e/ou informativas a serem usadas para se conceber o sistema de classificação.

Podemos alinhar os algoritmos seletores de características em três pilares:

I - Melhoria do desempenho do classificador aplicado;

II - Proporcionar preditores mais rápidos e mais eficazes;

III - Permitir uma melhor compreensão do processo gerador dos dados;

A seleção de característica para o presente trabalho foi feita utilizando-se o coeficiente de correlação de Pearson. A determinação do coeficiente de correlação é uma abordagem estatística que nos permite quantificar a força da associação. O cálculo produz a associação linear entre dois canais que é então usada para selecionar os mais dominantes.

Com base no coeficiente de correlação, uma matriz de classificação é desenvolvida. Os canais com classificação mais alta são classificados como

canais ativos ou sinais de imagens motoras reais, enquanto os canais com classificação mais baixa são considerados canais não representativos de sinais de imagens motoras. Aqueles com coeficientes de correlação mais baixos também podem ser interpretados como artefatos, ruído ou outros sinais que não estão correlacionados com os sinais de imagens motoras.

O coeficiente de correlação entre os dois intervalos em cada grupo é uma medida de quão próxima é a relação linear que esses dois intervalos possuem. Dado um par de dois canais, o coeficiente de correlação é definido da seguinte forma:

$$\rho_{i,j} = \frac{E[(i - \mu_i)(j - \mu_j)]}{\sigma_i \sigma_j} \quad (12)$$

### 3.5 Classificação

Em BCI os dados de entrada do sistema de classificação são os atributos extraídos do sinal cerebral e as classes são os possíveis comandos dado pelo usuário do sistema BCI.

O desempenho do classificador é determinado pela taxa de acerto entre o comando identificado, a partir das características extraídas do sinal EEG, e o comando realmente desejado pelo usuário do sistema.

Os sistemas BCI podem ser concebidos empregando tanto classificadores lineares, quanto não lineares. Para o presente trabalho foram implementadas as técnicas de classificação linear SVM e não linear MLP a fim de se analisar o desempenho da BCI criada.

A rede neural MLP é uma extensão imediata da rede perceptron de camada única, ela é capaz de tratar mais classes e propor hiperplanos não lineares, justamente por ter camadas de neurônios intermediárias (ocultas). Para o presente trabalho foram considerados 150 neurônios na camada oculta e uma janela de 5000 iterações.

O aprendizado da MLP ocorre por meio de algoritmos capazes de determinar os pesos de cada neurônio, tanto das camadas intermediárias como da camada de saída, de modo que todos os parâmetros da rede estejam sintonizados de maneira iterativa. Para o presente trabalho, foi utilizada a taxa de aprendizagem de 0,5%.

## 4 Resultados

Nesta seção, são apresentados os resultados obtidos com as técnicas de filtragem e com o método de extração de características. Todas as técnicas apresentadas não levam em consideração o desempenho da BCI e sim a eficiência do método ao sinal, de uma forma empírica.

Logo, para a classificação do melhor método de filtragem são apresentados os sinais no tempo e na frequência dos filtros CAR e CCA. O sinal foi coletado no eletrodo Oz, a partir de estímulos nas frequências de: 10Hz, 12Hz e 15Hz. É possível observar um padrão na amplitude dos sinais pós filtragem e também apresenta uma maior suavidade no tempo e na frequência.




Figura 4 – Sinal Temporal de Coleta no Eletrodo Oz - Sem Pré - Processamento




Figura 5 – Sinal Temporal de Coleta no Eletrodo Oz - Filtro CAR




Figura 6 – Sinal Temporal de Coleta no Eletrodo Oz - Filtro CCA

Como é possível observar nas figuras a amplitude dos sinais filtrados possuem um padrão ao longo do tempo e há uma redução significativa na magnitude.




Figura 7 – Espectro de Frequência Eletrodo Oz - Sem Filtragem




Figura 8 – Espectro de Frequência Eletrodo Oz - Filtro CAR




Figura 9 – Espectro de Frequência Eletrodo Oz - Filtro CCA




Figura 10 – PSD das frequências de 10Hz, 12Hz e 15Hz

Analisando as figuras 5,6 e 7 é possível observar que o espectro do sinal para as frequências desejadas é completamente alterado. É possível identificar um aumento de pico em todas as frequência dos filtros CAR e CCA, porém, a atenuação das frequências laterais utilizando o método de filtragem CCA é a mais significativa, atribuindo a mesma a escolha como melhor método para se utilizar no momento. Levando



em consideração que o desempenho da BCI que é o relevante nessa decisão de filtro a ser escolhido e não a apresentação do sinal no tempo ou na frequência.

A matriz de atributos é importante para validar e mensurar o sistema BCI, pois contém as informações das características do sistema, estas que serão fundamentais par a classificação do sinal.




Figura 11 – Coeficientes de Frequência da Matriz de Atributos H a partir da técnica de FFT




Figura 12 – Coeficientes de Frequência da Matriz de Atributos H a partir da técnica de Pwelch

booktabs multirow

Melhores Eletrodos	Mapeamento		
	Ref 10Hz	Ref 12Hz	Ref 15Hz
<b>51</b>	49	50	51
<b>53</b>	52	53	54
<b>153</b>	151	152	153
<b>189</b>	187	188	189
<b>18</b>	16	17	18
<b>175</b>	175	176	177
<b>63</b>	61	62	63
<b>13</b>	13	14	15
<b>168</b>	166	167	168

Utilizando os 9 melhores eletrodos, a taxa de erro da BCI ficou aproximadamente de 70%. Foi notado ao longo das simulações que o número ideal de eletrodos seriam 3 e trariam o melhor desempenho na BCI

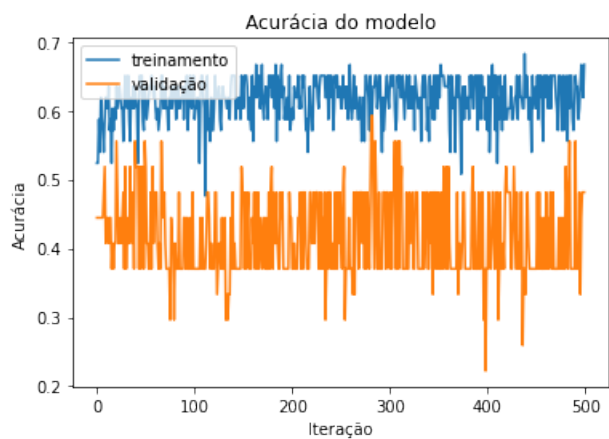


Figura 13 – Classificador MLP utilizando FFT a partir dos 3 melhores eletrodos

## 5 Conclusão

Nas etapas de pré processamento do sinal de EEG, foram separados, satisfatoriamente, 80% dos dados para treinamento e 20% dos dados para validação. O melhor desempenho para a BCI foi alcançado utilizando o filtro CCA nesta etapa. Na etapa subsequente, de extração de características, tanto a extração via FFT quanto a

extração via Pwelch trouxeram resultados aproximados no desempenho da BCI. Ambos resultados foram satisfatórios para o desempenho da BCI. Na etapa de seleção de características, foram encontrados os 9 melhores eletrodos, aqueles que apresentaram a melhor correlação. Para aplicação no Classificador, a partir da inserção do quarto eletrodo, a acuracidade da BCI diminuía e foi implementado o classificador com apenas os 3 melhores eletrodos. Os classificadores SVM e MLP apresentaram resultados aproximados entre si. Ambos apresentaram acuracidade entre 50% e 60%. Por fim, a implementação da BCI fora melhor aplicada ao Classificador Linear SVM com a extração de características por meio da técnica de FFT após aplicação do filtro CCA.

O classificador com base na rede MLP possui capacidade de aproximação universal, ou seja, ela é apta a encontrar qualquer função necessária para a resolução do problema proposto. No entanto, apesar da capacidade de modelar funções complexas, é necessário que ela seja ajustada de maneira correta e podendo estar susceptível à mais erros.

## Referências

- [1] Análise de correlação canônica como estratégia de préprocessamento e extração de características em sistemas bci-ssvep. Cbeb , [S. l.], p. 1-5, 6 jun. 2016.
- [2] Theodoridis S, Koutroumbas. Pattern Recognition. 4th ed. Academics Press, 2008
- [3] Suarez L, Cardozo E, Attux R, Soriano DC. An implementation of SSVEP-BCI system based on a cluster measure for feature selection. IEEE Biosignals and Biorobotics conference, 2014: Salvador, 26-28/05: 1-6.
- [4] Hermann CS. Human EEG responses to 1-100 Hz Flicker: Resonance Phenomena in Visual Cortex and their potential correlation to cognitive phenomena. Experimental Brain Research; 2001; 137: 346-353.
- [5] Y. Zhang, P. Xu, K. Cheng, and D. Yao, "Multivariate synchronization index for frequency recognition of SSVEP-based brain-computer interface," J. Neurosci. Methods, vol. 221, pp. 32–40, 2014.
- [6] A. Riccio, D. Mattia, L. Simione, M. Olivetti, and F. Cincotti, "Eye-gazeindependent EEG-based brain-computer interfaces for communication," J. Neural Eng., vol. 9, no. 4, p. 045001, 2012.
- [7] Bernat, E. M., Nelson, L. D., Holroyd, C. B., Gehring, W. J. Patrick, C. J. Separating cognitive processes with principal components analysis of EEG time-frequency distributions. In Advanced Signal Processing Algorithms, Architectures, and Implementations XVIII. (Vol. 7074, p. 70740S). (International Society for Optics and Photonics) (2008).
- [8] Arvaneh M, Guan C, Ang KK, Quek C. EEG data space adaptation to reduce inter-session nonstationarity in brain-computer interface. Neural Comput. 2013;25:2146–2171. doi: 10.1162/NECO\_a00474. – DOI – PubMed
- [9] WANG, Yijun et al. A benchmark dataset for SSVEP-based brain-computer interfaces. IEEE Transactions on Neural Systems and Rehabilitation Engineering, v. 25, n. 10, p. 1746-1752, 2016.
- [10] VEGA-ESCOBAR, L.; CASTRO-OSPINA, A. E.; DUQUE-MUÑOZ, L. Feature extraction schemes for BCI systems. In: 2015 20th symposium on signal processing, images and computer vision (STSIVA). IEEE, 2015. p. 1-6.
- [11] OIKONOMOU, Vangelis P. et al. Comparative evaluation of state-of-the-art algorithms for SSVEP-based BCIs. arXiv preprint arXiv:1602.00904, 2016.